ACÁMICA

¡Bienvenidos/as a Data Science!

Agenda

¿Cómo anduvieron?

Repaso: Redes Neuronales

Hands-On

Break

Terminología (extra) de Redes Neuronales

Actividad: Kahoot

Cierre

¿Cómo anduvieron?

Repaso:
Redes Neuronales

Perceptrón con una variable

Necesitamos algo que, dado los features, devuelva probabilidades.
Las probabilidades deben estar entre 0 y 1

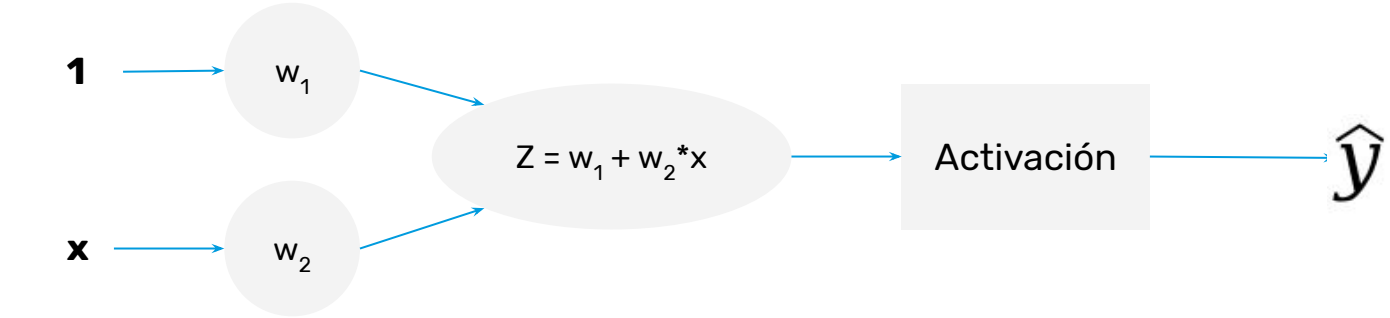

Entradas: Features + Bias

Pesos: Lo que buscamos en el entrenamiento

Unión sumadora: combina los features con los pesos

Activación: si no está, ¡es una función lineal!

Salida: entre 0 y 1, probabilidad del evento

Perceptrón con una variable

Necesitamos algo que, dado los features, devuelva probabilidades.
Las probabilidades deben estar entre 0 y 1

Otra representación

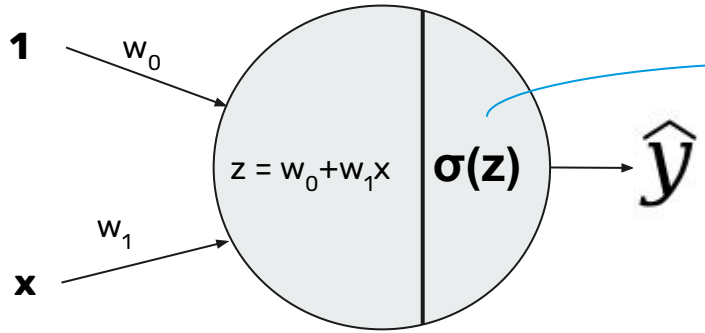

Activación:

- Sin la activación, es una función lineal
- Necesitamos introducir algo que *sature* la entrada en 0 o en 1 dependiendo del resultado de la unión sumadora

Función Logística / Sigmoide

$$y(z) = \frac{1}{1 + e^{-z}}$$

$$z = w_0 + w_1 x$$

$$y(x) = \frac{1}{1 + e^{-(w_0 + w_1 x)}}$$

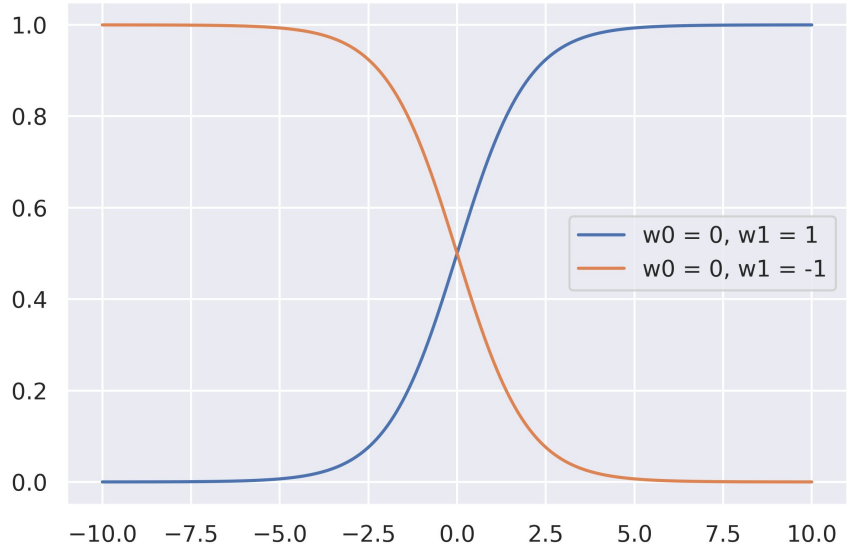

Entropía cruzada (cross-entropy)

Necesitamos una función de pérdida entre una etiqueta (y) y la probabilidad de pertenecer o no a esa etiqueta. $\hat{y}$

Caso binario: etiquetas y = 0 y 1.

$$L(\hat{y}, y) = -y * log(\hat{y}) - (1 - y) * log(1 - \hat{y})$$

Pérdida para una instancia

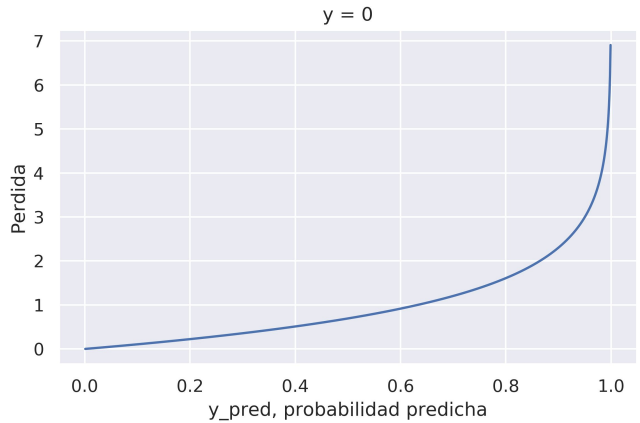

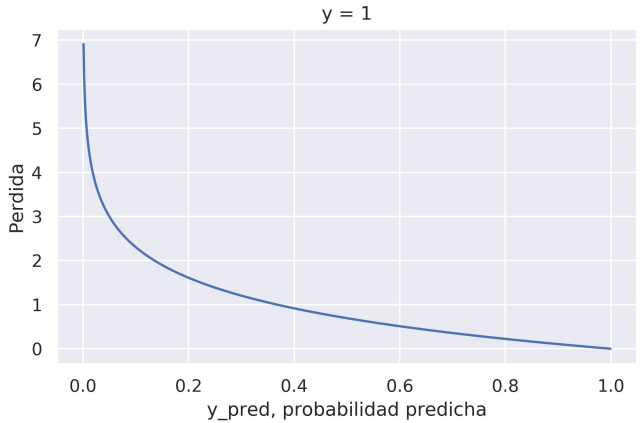

Entropía cruzada (cross-entropy)

Necesitamos una función de pérdida entre una etiqueta (y) y la probabilidad de pertenecer o no a esa etiqueta. $\hat{y}$

Caso binario: etiquetas y = 0 y 1.

$$L(\hat{y}, y) = -y * log(\hat{y}) - (1 - y) * log(1 - \hat{y})$$ **Pérdida para una instancia**

Entropía cruzada (cross-entropy)

Necesitamos una función de pérdida entre una etiqueta (y) y la probabilidad de pertenecer o no a esa etiqueta. $\hat{y}$

Caso binario: etiquetas y = 0 y 1.

$$L(\hat{y}, y) = -y * log(\hat{y}) - (1 - y) * log(1 - \hat{y})$$

Pérdida para una instancia

$$J(\overline{W}) = \frac{1}{n} \sum_{i=0}^{n-1} L(\widehat{y^{(i)}}, y^{(i)})$$

Costo para todas las instancias

Entropía cruzada (cross-entropy)

Necesitamos una función de pérdida entre una etiqueta (y) y la probabilidad de pertenecer o no a esa etiqueta. $\hat{y}$

Caso binario: etiquetas y = 0 y 1.

$$L(\hat{y}, y) = -y * log(\hat{y}) - (1 - y) * log(1 - \hat{y})$$

Pérdida para una instancia

$$J(\overline{W}) = \frac{1}{n} \sum_{i=0}^{n-1} L(\widehat{y^{(i)}}, y^{(i)})$$

Costo para todas las instancias

$$J(w_0,\ w_1) = \frac{1}{n} \sum_{i=0}^{n-1} L(\widehat{y^{(i)}}, y^{(i)})$$

Costo para todas las instancias, caso 1D

1. Descenso por gradiente calcula la derivada/gradiente del costo y con eso actualiza los parámetros. Este proceso lo va a hacer muchas veces hasta llegar al mínimo.
2. En cada una de esas iteraciones, tiene que calcular el costo. El costo depende de las instancias de entrenamiento y de los parámetros que tengamos hasta ese momento.

Calcular el costo con las instancias de entrenamiento es lo que se conoce como **Forward Propagation.**

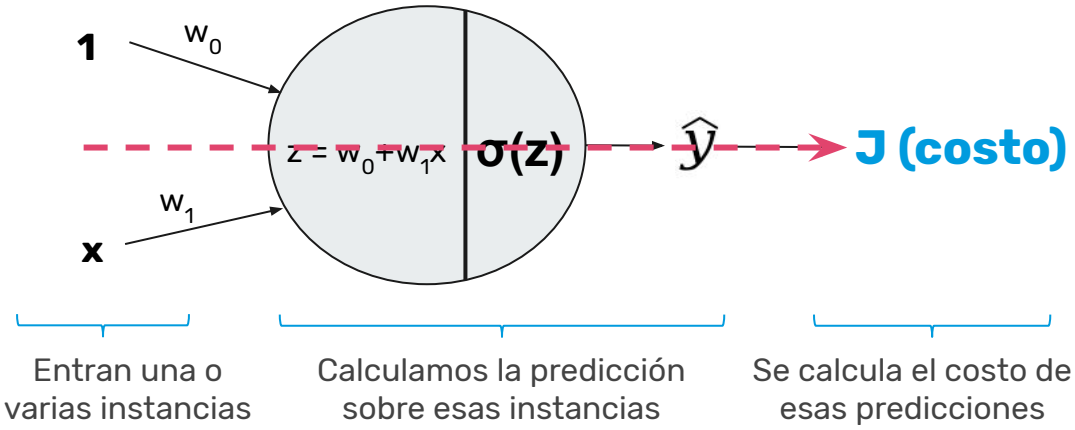

1. Con el costo calculado, queremos actualizar los valores de los parámetros según la regla vista en la clase anterior.
2. Para eso, tenemos que derivar el costo y propagar esa derivada hacia atrás, hasta llegar a los parámetros w_0 y w_1.

Calcular las derivadas y actualizar los parámetros "hacia atrás" se conoce como **Backpropagation.**

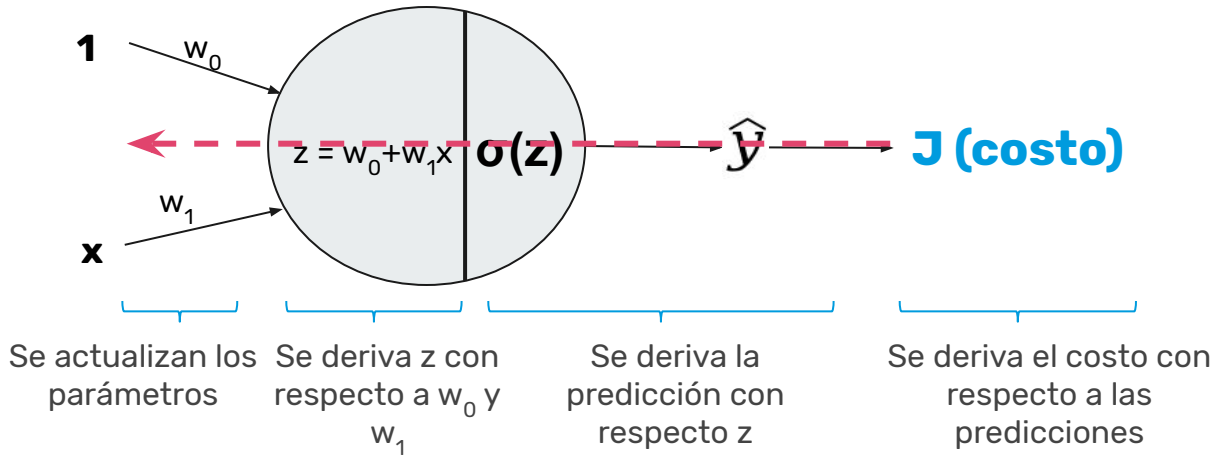

Perceptrón Multicapa

Ampliando el Perceptrón

Problema con el Perceptrón:
solo encuentra fronteras lineales.

Ampliando el Perceptrón

Solución: Perceptrón Multicapa

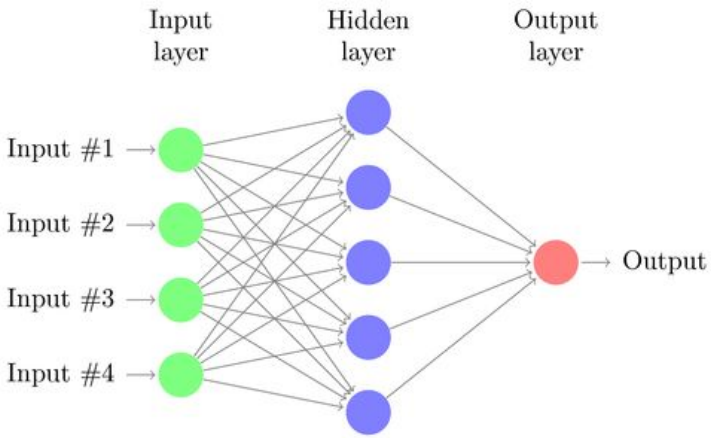

- Cada neurona tiene sus propios pesos/parámetros. En aplicaciones comunes suelen ser desde miles a millones de parámetros para toda la red.
- **Deep Learning es** encontrar esos pesos de manera eficiente, bajo la condición de realizar correctamente una tarea objetivo.

Perceptrón Multicapa • Funciones de activación

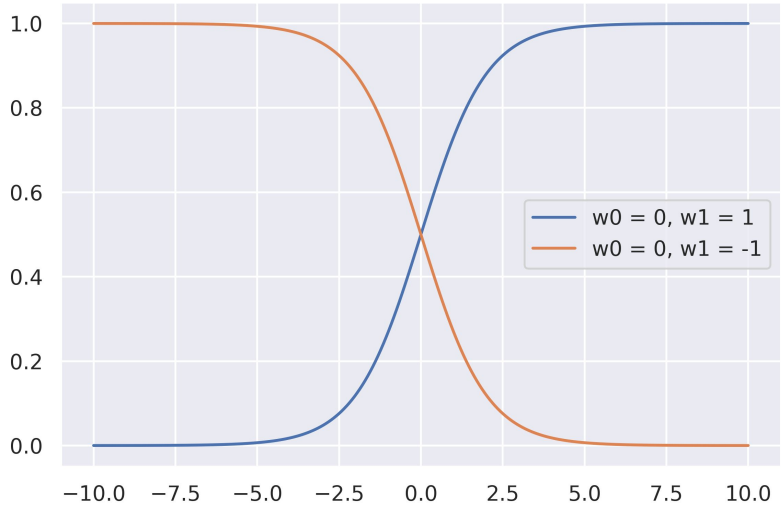

1. **Sigmoide/logística**
2. Identidad: f(x) = x
3. Escalón: f(x)=0 si x<0, 1 si x≥0
4. Tangente Hiperbólica: f(x)=tanh(x)
5. ReLU: f(x)=0 si x<0, x si x≥0

Perceptrón Multicapa • Funciones de activación

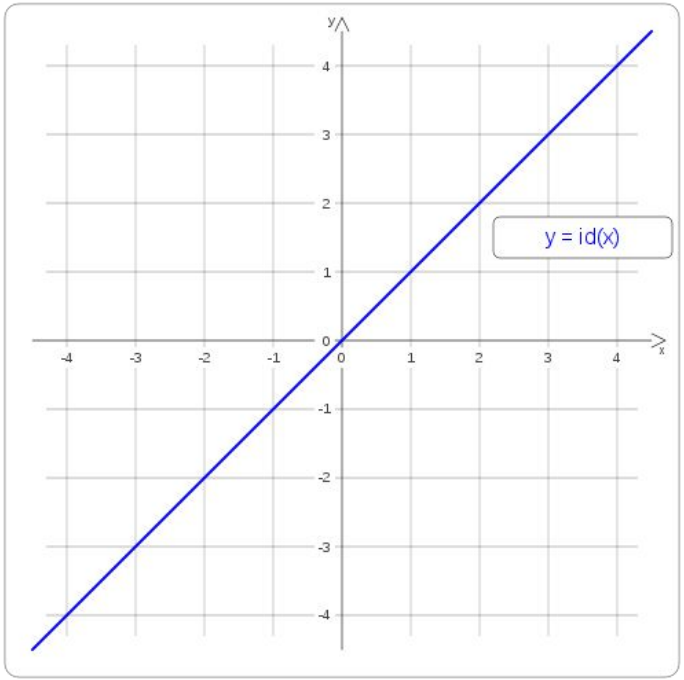

1. Sigmoide/logística
2. **Identidad: f(x) = x**
3. Escalón: f(x)=0 si x<0, 1 si x≥0
4. Tangente Hiperbólica: f(x)=tanh(x)
5. ReLU: f(x)=0 si x<0, x si x≥0

Perceptrón Multicapa • Funciones de activación

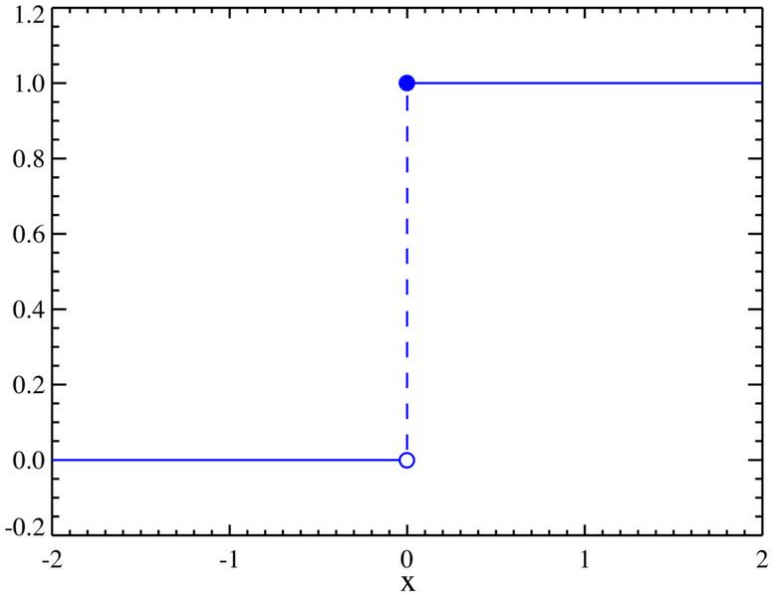

1. Sigmoide/logística
2. Identidad: f(x) = x
3. **Escalón: f(x)=0 si x<0, 1 si x≥0**
4. Tangente Hiperbólica: f(x)=tanh(x)
5. ReLU: f(x)=0 si x<0, x si x≥0

Perceptrón Multicapa • Funciones de activación

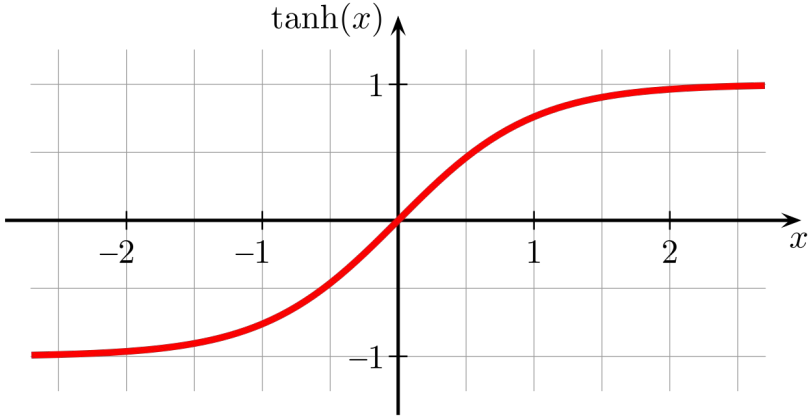

1. Sigmoide/logística
2. Identidad: f(x) = x
3. Escalón: f(x)=0 si x<0, 1 si x≥0
4. **Tangente Hiperbólica: f(x)=tanh(x)**
5. ReLU: f(x)=0 si x<0, x si x≥0

Perceptrón Multicapa • Funciones de activación

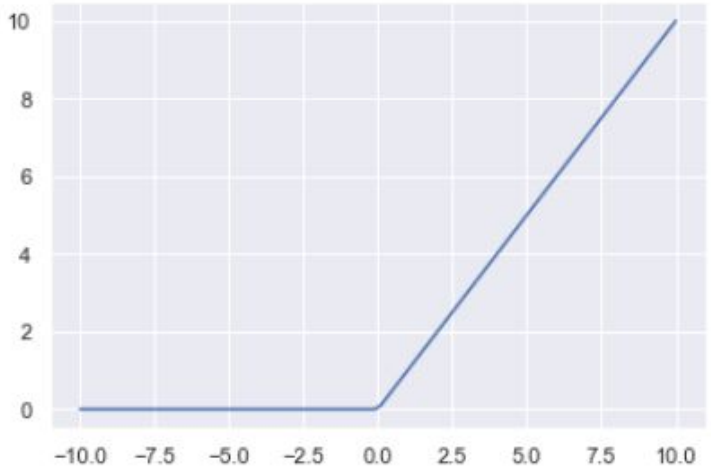

1. Sigmoide/logística
2. Identidad: f(x) = x
3. Escalón: f(x)=0 si x<0, 1 si x≥0
4. Tangente Hiperbólica: f(x)=tanh(x)
5. **ReLU: f(x)=0 si x<0, x si x≥0**

Perceptrón Multicapa • Funciones de activación

Clasificación:
lo más común es encontrar ReLU en las capas interiores y Sigmoide en la salida

1. **Sigmoide/logística**
2. Identidad: f(x) = x
3. Escalón: f(x)=0 si x<0, 1 si x≥0
4. Tangente Hiperbólica: f(x)=tanh(x)
5. **ReLU: f(x)=0 si x<0, x si x≥0**

Perceptrón Multicapa

	Funciones de activación	**Costos (Keras)**
Multiclase	1. Sigmoide/logística 2. Softmax	Categorical_crossentropy
Regresión	Identidad	1. mean_squared_error 2. mean_absolute_error 3. Otras

Perceptrón Multicapa

	Funciones de activación	Costos (Keras)
Multiclase	1. Sigmoide/logística **2. Softmax**	Categorical_crossentropy
Regresión	Identidad	1. mean_squared_error 2. mean_absolute_error 3. Otras

Generalización de la sigmoide, útil cuando las clases son excluyentes.

Hands-on training

Hands-on training

DS_Encuentro_31_Perceptron_Multicapa.ipynb

¡BREAK!

Ph. Credit: Drew Coffmann

Terminología (extra) de Redes Neuronales

- Regularización
- Batch size
- Epochs
- CNN (Convolutional Neural Networks)

Regularización

Objetivo: castigar parámetros/pesos muy grandes.

están asociados a overfitting.

Regularización

Objetivo: castigar parámetros/pesos muy grandes.

están asociados a overfitting.

¿Cómo? Tres técnicas muy comunes

- Regularización L2 y L1: agregan un término a la función de costo que castiga los pesos grandes.
- **Dropout:** funciona como una capa que “apaga” neuronas de la capa anterior al azar.

Regularización

¿Cómo?

Dropout: funciona como una capa que “apaga” neuronas de la capa anterior al azar.

Muy utilizado. Al apagar neuronas, obliga a que ninguna se aprenda “de memoria” una muestra, sino que tengan que aprender entre todas.
Otra interpretación: Ensamble

Batch size

Observación: En muchos casos, el proceso de hacer Forward-propagation y back-propagation puede ser computacionalmente muy costoso.

¿Por qué? Al tener muchas instancias y muchas neuronas, hay que realizar muchas operaciones cada vez que queremos actualizar los parámetros.

Solución: Separamos nuestro dataset en distintos grupos o 'lotes' (batch).

Batch size

- **Ventaja:** Converge mas rápido (llego antes al mínimo)
- **Desventaja:** El 'camino' (en términos de los parámetros) al máximo no es el 'ideal'

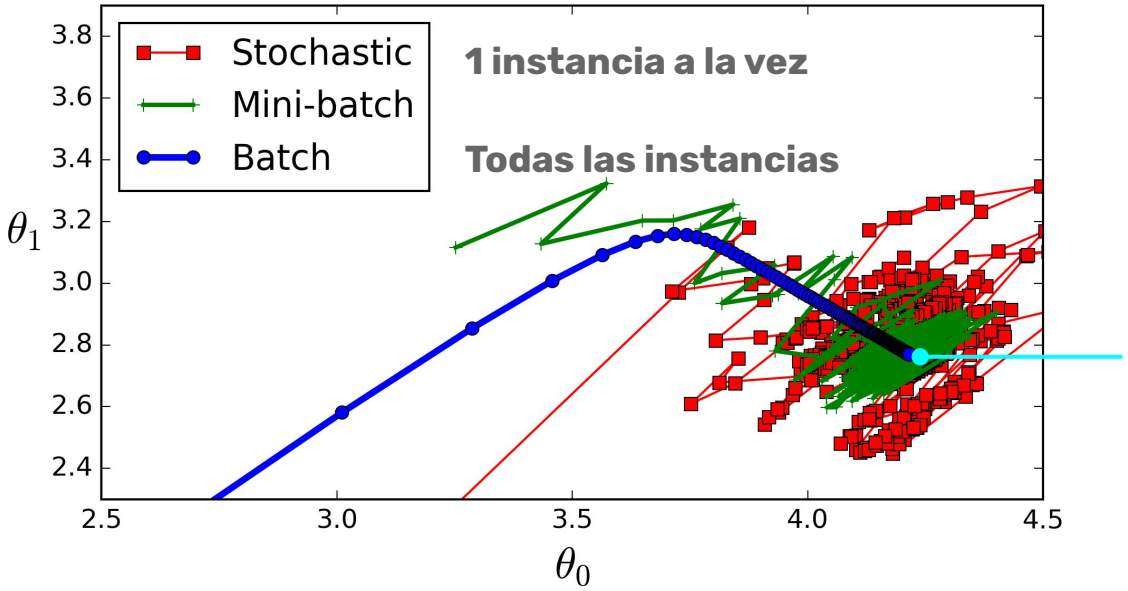

Epochs

Definición: Es el parámetro que controla la cantidad de veces que 'pasamos' (hacemos Forward y Backpropagation) sobre todo el dataset (todas las instancias).

Observación: Si el batch_size es menor a la cantidad total de instancias N, entonces habrá que 'pasar' varias veces para lograr 1 Epoch.

CNNs: Convolutional Neural Networks

Definición: Son un tipo particular de redes neuronales.

¿Para qué sirven? Son muy buenas para trabajar con imágenes, pero demostraron funcionar bien para diversa clases de problemas

¿Cómo funcionan? La idea principal es que las neuronas del input no ven todos los datos, solo ven partes de los datos (una región). Veremos más de esto el encuentro que viene.

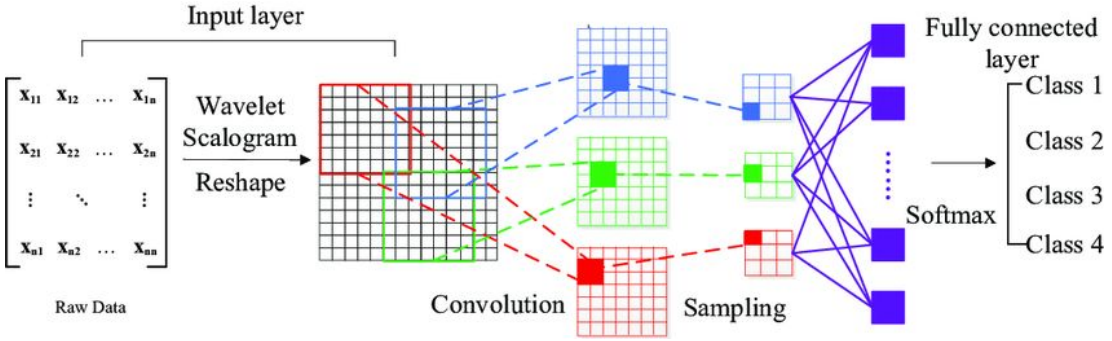

Actividad


Kahoot!

Para la próxima:
Data Science en mi vida

Data Science en mi vida

¡Preparen sus charlas relámpago!
En 7 minutos con 7 slides comparte con tus compañeros:

En qué problemas estás aplicando lo aprendido en Data Science y cómo lo estás haciendo.
O bien, en qué problemas te gustaría aplicar Data Science y cómo lo harías.

¡Elige algún tema o proyecto que te interese y relaciónalo con lo aprendido!

Para la próxima

1. Ver los videos de la plataforma “Procesamiento del lenguaje natural”

2. Terminar notebook de hoy y atrasados.

3. Preparar el relato “Data Science en mi vida”.

ACÁMICA